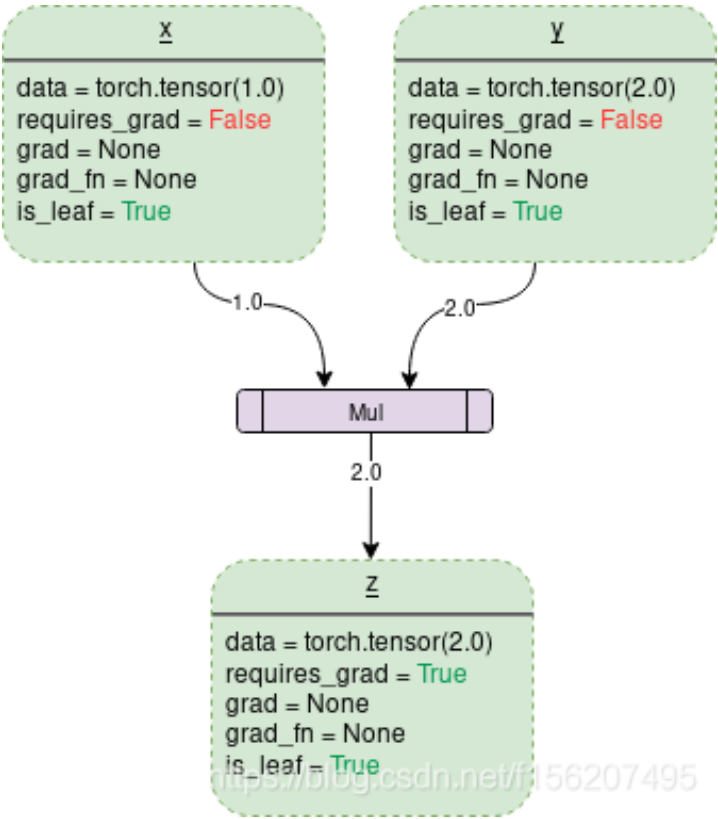


可参考网页：https://blog.csdn.net/f156207495/article/details/88727860?ops_request_misc=%257B%2522request%255Fid%2522%253A%2522162642304616780261996447%2522%252C%2522scm%2522%253A%25220140713.130102334..%2522%257D&request_id=162642304616780261996447&biz_id=0&utm_medium=distribute.pc_search_result.none-task-blog-2~all~sobaiduend~default-1-88727860.first_rank_v2_pc_rank_v29&utm_term=pytorch+grad&spm=1018.2226.3001.4187

1 一些参数

tensor在pytorch里面是一个n维数组。我们可以通过指定参数reuiques_grad=True来建立一个反向传播图，从而能够计算梯度。



requires_grad：布尔变量（True/False），需要计算该Tensor梯度时，将其设置为True

.grad_fn：表示用于计算梯度的函数。每个Tensor都有一个.grad_fn属性。如果该Tensor是通过某些运算得到的，那么调用该属性就会返回一个与该运算相关的对象，否则返回None

is_leaf：为True或者False，表示该节点是否为叶子节点

当调用backward函数时，只有requires_grad为true以及is_leaf为true的节点才会被计算梯度，即grad属性才会被赋值。

```

x = torch.ones(3, 3, requires_grad=True)
y = x * x
z = x + 1

print(x)
print(x.grad_fn)
print(y)
print(y.grad_fn)
print(z)
print(z.grad_fn)

```

输出

```

# x:
tensor([[1., 1., 1.],
        [1., 1., 1.],
        [1., 1., 1.]], requires_grad=True)
None

# y:
tensor([[1., 1., 1.],
        [1., 1., 1.],
        [1., 1., 1.]], grad_fn=<MulBackward0>)
<MulBackward0 object at 0x7fe768298940>

# z:
tensor([[2., 2., 2.],
        [2., 2., 2.],
        [2., 2., 2.]], grad_fn=<AddBackward0>)
<AddBackward0 object at 0x7fd9801a0940>

```

- 可以采用in_place方式改变 `requires_grad` 属性

```

x = torch.ones(3, 3)
x = x * x + 2

print(x.requires_grad)
print(x.grad_fn)

x.requires_grad_(True)

print(x.requires_grad)
print(x.grad_fn)

```

输出

```
False
None
True #虽然requires_grad被修改为True
None #但是.grad_fn属性仍为None，因为x是由自己运算得到的
```

2 求梯度示例

```
x = torch.ones(2, 2, requires_grad=True)
y = x + 2
z = y * y * 3
out = z.mean() #求平均值,out=tensor(27., grad_fn=<MeanBackward0>)

out.backward() #反向传播求梯度，结果存储在x.grad中
print(x.grad)
```

输出

```
tensor([[4.5000, 4.5000],
        [4.5000, 4.5000]])
```

解释

$$x = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$$

$$z = 3(x+2)^2$$

$$out = \frac{1}{4} \sum_{i=1}^4 3(x_i+2)^2$$

$$out.backward() \text{ 就相当于求 } \frac{d(out)}{dx}$$

$$x_{i=1}, \text{ 也即 } \frac{\partial o}{\partial x_i} \big|_{x_i=1} = \frac{1}{4} \times 2 \times 3(x_i+1) = \frac{9}{2} = 4.5$$

求得的梯度值存在x.grad属性中

因此调用 x.grad 可得 $\text{tensor}(\begin{bmatrix} 4.5 & 4.5 \\ 4.5 & 4.5 \end{bmatrix})$

数学上，如果有一个函数值和自变量都为向量的函数 $\vec{y} = f(\vec{x})$ ，那么 \vec{y} 关于 \vec{x} 的梯度就是一个雅可比矩阵（Jacobian matrix）：

$$J = \begin{pmatrix} \frac{\partial y_1}{\partial x_1} & \cdots & \frac{\partial y_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial y_m}{\partial x_1} & \cdots & \frac{\partial y_m}{\partial x_n} \end{pmatrix}$$

而 `torch.autograd` 这个包就是用来计算一些雅可比矩阵的乘积的。例如，如果 v 是一个标量函数的 $l = g(\vec{y})$ 的梯度：

$$v = \left(\frac{\partial l}{\partial y_1} \quad \cdots \quad \frac{\partial l}{\partial y_m} \right)$$

那么根据链式法则我们有 l 关于 \vec{x} 的雅可比矩阵就为：

$$vJ = \left(\frac{\partial l}{\partial y_1} \quad \cdots \quad \frac{\partial l}{\partial y_m} \right) \begin{pmatrix} \frac{\partial y_1}{\partial x_1} & \cdots & \frac{\partial y_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial y_m}{\partial x_1} & \cdots & \frac{\partial y_m}{\partial x_n} \end{pmatrix} = \left(\frac{\partial l}{\partial x_1} \quad \cdots \quad \frac{\partial l}{\partial x_n} \right)$$

- 注意：grad在反向传播过程中是累加的(accumulated)，这意味着每一次运行反向传播，梯度都会累加之前的梯度，所以一般在反向传播之前需把梯度清零。

```
out2 = x.sum()
out2.backward()
print(x.grad)
print(out2)
```

输出

```
tensor([[5.5000, 5.5000],
        [5.5000, 5.5000]])
tensor(4., grad_fn=<SumBackward0>)
"""
可以看到，x.grad的值等于out关于x的梯度值+out2关于x的梯度值之和
4.5 + 1.0
"""
```

清零操作

```
x.grad.data.zero_()
```

```
x.grad.data.zero_()

out2 = x.sum()
out2.backward()
print(x.grad)

#输出
tensor([[1., 1.],
        [1., 1.]])
```

- 注意：在 `y.backward()` 时，如果 `y` 是标量，则不需要为 `backward()` 传入任何参数；否则，需要传入一个与 `y` 同形的 Tensor。

(只允许标量对张量求导，不允许张量对张量求导)

如前例子中，`out` 为标量 $\rightarrow out = z.mean()$ 就相当于 $out = \vec{z} \cdot \vec{w} = \vec{z} \cdot (\frac{1}{4}, \frac{1}{4}, \frac{1}{4}, \frac{1}{4})$ ，也即把张量为标量的过程

$$out = \frac{1}{4} \sum_{i=1}^4 z_i \quad \text{梯度} \quad \frac{\partial out}{\partial \vec{z}} = \left(\frac{\partial out}{\partial z_1}, \frac{\partial out}{\partial z_2}, \frac{\partial out}{\partial z_3}, \frac{\partial out}{\partial z_4} \right)$$

$$z = 3y^2 \quad \text{梯度} \quad \frac{\partial \vec{z}}{\partial \vec{y}} = \begin{pmatrix} \frac{\partial z_1}{\partial y_1} & \dots & \frac{\partial z_1}{\partial y_4} \\ \vdots & & \vdots \\ \frac{\partial z_4}{\partial y_1} & \dots & \frac{\partial z_4}{\partial y_4} \end{pmatrix}$$

$$y = x + 2$$

$$\frac{\partial \vec{y}}{\partial \vec{x}} = \begin{pmatrix} \frac{\partial y_1}{\partial x_1} & \dots & \frac{\partial y_1}{\partial x_4} \\ \vdots & & \vdots \\ \frac{\partial y_4}{\partial x_1} & \dots & \frac{\partial y_4}{\partial x_4} \end{pmatrix}$$

$$\begin{aligned} \text{从而根据链式法则，有} \quad \frac{\partial out}{\partial \vec{x}} &= \left(\frac{\partial out}{\partial z_1}, \frac{\partial out}{\partial z_2}, \frac{\partial out}{\partial z_3}, \frac{\partial out}{\partial z_4} \right) \times \begin{pmatrix} \frac{\partial z_1}{\partial y_1} & \dots & \frac{\partial z_1}{\partial y_4} \\ \vdots & & \vdots \\ \frac{\partial z_4}{\partial y_1} & \dots & \frac{\partial z_4}{\partial y_4} \end{pmatrix} \\ &\times \begin{pmatrix} \frac{\partial y_1}{\partial x_1} & \dots & \frac{\partial y_1}{\partial x_4} \\ \vdots & & \vdots \\ \frac{\partial y_4}{\partial x_1} & \dots & \frac{\partial y_4}{\partial x_4} \end{pmatrix} = \left(\frac{\partial out}{\partial x_1}, \frac{\partial out}{\partial x_2}, \frac{\partial out}{\partial x_3}, \frac{\partial out}{\partial x_4} \right) \\ &= \frac{\partial out}{\partial \vec{x}} \quad (\text{标量对张量求导}) \end{aligned}$$

如果允许张量对张量求导结果会更加复杂

因此计算 `y.backward()` 时，

若 `y` 为一个 tensor，就须要传入一个与 `y` 同型的 tensor `w`

相当于先计算 $\vec{y} \cdot \vec{w}$ (点乘，结果为标量)

再计算梯度

\vec{w} 默认为 $(1, 1, \dots, 1)$ ，也可带权，如 $(0.1, 0.5, \dots, 1)$

```
x = torch.tensor([1.0, 2.0, 3.0, 4.5], requires_grad=True)
y = x * x + 2
z = y.view(2, 2)
w = torch.tensor([[1.0, 0.1], [1.0, 0.01]]) #传入的与z同型的带权张量

z.backward(w)
print(x.grad)

#输出
tensor([2.0000, 0.4000, 6.0000, 0.0900])
```

- 中断梯度追踪

with `torch.no_grad()` 将不想被追踪的操作代码块包裹起来。

这种方法在评估模型的时候很常用，因为在评估模型时，我们并不需要计算可训练参数（`requires_grad=True`）的梯度

```
x = torch.tensor(1., requires_grad=True)
y1 = x ** 2
with torch.no_grad():
    y2 = x ** 3
y3 = y1 + y2

y3.backward()
print(f"x.grad = {x.grad}")
print(f"y2.requires_grad = {y2.requires_grad}")

#输出
x.grad = 2.0
y2.requires_grad = False #由于被阻断了梯度追踪，因此requires_grad属性值为False
"""
如果没有中断y2的梯度追踪，那么y3=x^2+x^3,从而y3对x求导的结果为2x+3x^2,代入x=1，梯度值应为5
而由于中断了对y2的梯度追踪，从而实际上y3=x^2+1,从而y3对x的求导结果为2x,代入x=1，实际梯度值为2
"""
```

- 修改tensor数值而不影响求导

此外，如果我们想要修改 `tensor` 的数值，但是又不希望被 `autograd` 记录（即不会影响反向传播），那么我们可以对 `tensor.data` 进行操作。

```
x = torch.ones(1,requires_grad=True)

print(x.data) # 还是一个tensor
print(x.data.requires_grad) # 但是已经是独立于计算图之外

y = 2 * x
x.data *= 100 # 只改变了值，不会记录在计算图，所以不会影响梯度传播

y.backward()
print(x) # 更改data的值也会影响tensor的值
print(x.grad)

#输出
tensor([1.])
False
tensor([100.], requires_grad=True)
tensor([2.])
```